

자율주행 로봇의 센서 데이터 처리 SLM 모델 연구

권형준¹, 박서연², 이동현², 이도근², 김동균^{*3}, 오재덕⁴

경북대학교 전자공학부¹, 컴퓨터학부²

경북대학교 컴퓨터학부 교수³

(주) LG 전자⁴

e-mail : hj4517@knu.ac.kr¹, seoyeonpak@knu.ac.kr², dongkyun@knu.ac.kr³, nicky.oh@lge.com⁴

SLM(Small Language Model) for Autonomous Robot Sensor Data Interpretation

Kyungpook National University¹²³

LG Electronics⁴

Abstract

An automated system that uses a small language model (SLM) to generate preliminary reports from inertial measurement unit (IMU) data of an autonomous robot. Our pipeline begins with preprocessing IMU time series data to de-noise and extract key features, which we cluster through PCA and K-Means to identify the operational status of the robot. To train SLM, we constructed a structured dataset using the YOLOv11 model to detect section titles in documents and OCR to extract corresponding text. We then used the Korean Polyglot-ko-5.8b model with quantized low-rank adaptation (QLoRA) to create a lightweight model suitable for edge devices such as Jetson Orin Nano. The system consists of React and Rust-based interfaces for user review and editing. Although the SLM model is not perfect, this study is meaningful in that it designed and implemented an entire pipeline that can be composed of documents after analyzing and storing unstructured data.

I. 서론

자율 이동 로봇은 IMU(Inertial Navigation System) 센서가 로봇의 각도 추정, 경로 계획의 핵심적인 역할을 한다. IMU는 로봇의 선형가속도와 각속도를 측정하며, 수집되는 데이터는 로봇의 움직임을 실시간으로 처리하여 1초에 수십개의 데이터가 시계열성으로 구성되며 이를 연구자가 직접 데이터 분석으로 처리하기엔 상당한 시간이 소모된다. 이러한 특성으로 인해, IMU 데이터를 자동으로 전처리해주고 핵심적인 의미를 추출하여 자동으로 보고서를 작성해주는 SLM을 개발한다.

기존 연구들이 센서 데이터의 이상 탐지나 특정 패턴을 분석에서 더 나아가 그 결과를 통한 서술적인 보고서를 생성하는 점에서 차별점을 가진다. 또한, QLoRA(Quantized Low-Rank Adaptation) 기반 경량화 기술[1]을 사용하여 엣지 디바이스 환경에서도 모델이 구동될 수 있도록 하여 속도 및 표준화 측면에서 혁신적인 이점을 제공한다.

* 교신저자(Corresponding Author): 김동균, 경북대학교 컴퓨터학부, dongkyun@knu.ac.kr

II. 연구방법

2.1 IMU 시계열 데이터 전처리

파인튜닝 된 SLM이 유의미한 보고서를 생성하기 위해선 자율주행 로봇의 IMU 센서 데이터가 수치화된 시계열 데이터이므로 의미를 추출하여 SLM 시스템에 넘겨주는 과정이 필요하다.

그렇기 때문에 Kaggle에 공개된 ROSBag IMU 데이터셋[2]을 이용했다. IMU 데이터셋에 이상치가 포함되어 있어 IsolationForest[3]를 사용하여 데이터의 밀도가 낮은 포인트를 이상치로 판단하고 제거했다. 이후, Kalman Filter[4]를 적용해 로봇의 위치 및 속도를 재귀적 관점으로 추정하여 궤적을 부드럽게 만들어 데이터의 노이즈를 제거해주고 속도를 최적화 했다.

2.2 IMU 데이터 특징 추출

2.1절에서 최적화된 IMU 데이터를 Sliding Window 기법을 적용해 특징을 추출해 냈다.

로봇 움직임의 Time-Domain 특성을 분석했을 때, RMS(Root Mean Square)을 추출해 가속 및 회전 강도를 파악했다. 또한, Frequency-Domain 영역의 특성을 FFT(Fourier transform)를 사용해 로봇의 주기적인 진동 및 주행 패턴[5]을 분석했다.

추출된 특징을 이용해 PCA(Principal Component Analysis)를 사용해 주요 성분을 추출하여 K-Means Clustering 알고리즘[6]을 적용해 유사한 특징을 가진 특징 데이터를 3개의 그룹으로 군집화 했다. 이 추출된 특징을 Comma-Separated Values(CSV)로 저장해 SLM의 입력으로 사용될 데이터를 생성해냈다.




그림 1 IMU 센서 데이터 생성 구조도

2.3 YOLO 기반 보고서 제목 영역 탐지 모델로 SLM 데이터 생성

보고서 생성 데이터셋을 생성해 내기 위해 한국과학기술정보연구원(KISTI) 보고서 목차 자동 생성 데이터셋[7]은 보고서의 이미지 파일과 이미지 내에 존재하는 각 섹션 제목의 위치 정보의 TXT 파일 쌍으로 구성되어 있다. 이를 YOLOv11m[8] 모델을 사용하여 ‘대

제목’ 2234개, ‘중제목’ 2514개, ‘소제목’ 1940개의 데이터를 이용해 3가지 ‘대제목’ ‘중제목’ ‘소제목’ 구조적 태그로 분류하는 모델을 생성했다.

2.4 SLM 파인튜닝을 위한 데이터셋 구축

EasyOCR reader[9]를 통해 위치에 따른 텍스트를 추출해 냈다. 이를 YOLO(You Only Look Once)v11 모델의 제목 블록과 위치에 따른 텍스트 내용을 IOU(intersection over union)를 사용하여 겹친 영역을 계산했다. IOU 임계값 0.5 이상 겹치지 않는 OCR(optical character recognition) 블록은 본문으로 간주하여 해당 텍스트가 섹션 제목인지 본문인지 알 수 있게 된다.

텍스트들을 Y좌표 및 X좌표 순서로 정렬하여 문서의 논리적 구조를 스택을 통해 재구성했다. ‘대제목’은 스택에 추가되고 이후 ‘중제목’ 및 ‘본문’은 ‘대제목’노드의 자식으로 삽입되어 보고서 페이지는 [그림]과 같이 문서의 구조를 반영한 JSON 형식으로 완성된다.

SLM이 보고서 작성의 학습을 용이하기 위해 3가지 역할을 할 수 있도록 학습데이터를 생성한다.

첫 번째는 SLM이 제목을 입력 후, 하위 목차를 생성할 수 있도록 하는 것이다.

두 번째는 SLM이 보고서의 목차 중 한 부분 및 섹션 제목을 입력 후, 그에 맞는 본문을 작성하도록 학습시킨다.

세 번째는 SLM이 본문 내용을 입력받아 그에 맞는 섹션 제목을 생성 하도록 학습한다.

이러한 방식을 통해 보고서의 구조를 기획하여 그에 맞는 내용을 작성하고 내용을 요약하여 제목을 작성하는 복합적인 SLM 모델이 가능하도록 데이터셋을 구성했다.




그림 2 OCR 보고서 데이터셋 생성 구조도

2.5 QLoRA 기반 SLM 모델 파인튜닝

2.4절에서 구축된 다중작업 데이터셋을 사용하여 ‘지시’와 ‘입력’ ‘응답’을 구분하여 모델에 맞게 데이터셋을 재구성했다.

자율주행 로봇용 엡지디바이스에서도 모델이 돌아갈 수 있게 QLoRA 4bit 양자화를 통해 GPU 메모리 사용량을 줄였다.

EleutherAI의 polyglot-ko-5.8b 모델[10]을 사용하여 4비트 NormalFloat(NF4) 양자화 타입을 사용해 정보 손실을 최소화하면서 가중치 근사화를 수행했고 Forward pass는 bfloat16을 사용하여 학습 성능을 높였다. 4비트로 양자화된 모델은 Low-Rank 어댑터 모델을 학습 모델의 Attention에 부착되어 학습 대상 파라미터 수를 전체의 2% 미만으로 파인튜닝하여 SLM 보고서 생성 초안 모델을 구성한다.

IMU 센서의 값을 입력으로 하여 파인튜닝한 SLM 모델을 이용해 보고서 초안 텍스트를 생성한다.




그림 3 전체 모델 학습 구조도

2.6 보고서 내용 수정 인터페이스 구축

2.5절에서 생성된 보고서 텍스트를 사용자 인터페이스에서 확인하고 수정을 할 수 있다. 백엔드는 Rust[11]의 Backend Architecture를 이용해 초기 구조체 형식으로 Parsing하여, 이를 Request Routing을 통해 사용자의 요청을 식별하고 Sharding을 통해 병렬로 처리 후, 재조립되어 프론트엔드로 반환되는 과정으로 보고서를 재구성 할 수 있다. 이런 과정으로 인터페이스가 구성되며 완성된 보고서를 Docs(documents) 형식으로 다운 받을 수 있다.




그림 4 프론트엔드 구조도




그림 5 백엔드 구조도

III. 연구 결과

3.1 IMU 데이터 특징 추출 결과

IMU 센서의 시계열 데이터를 통해 [그림 6]의 그래프에서 RMS와 표준 편차는 급격한 피크의 구간이 시스템의 외부 충격이 발생한 구간과 일치함을 판별했고 FFT 기반 평균 값 및 최대 진폭이 일정한 패턴으로 반복되는 구간은 주기적 움직임이 있는 부분임을 확인했다. 이러한 특성은 IMU 센서 기반으로 자율주행 로봇의 주행 움직임 판별의 객관적 지표로 활용될 수 있다.

추출한 지표를 PCA(Principal Component Analysis)로 2차원으로 축소하여 데이터간 상관성을 추출하여 로봇의 동작을 3가지로 분류하였다. 이렇게 분류한 각 Cluster는 로봇의 의미론적인 부분을 특정해 낼 수 있어 SLM이 보고서 생성하는데 활용한 핵심지표가 된다.

3가지 상태 분류를 [그림 7]을 통해 확인할 수 있다. Cluster 0은 낮은 RMS와 FFT로 정지 및 저가속 구간이다. Cluster 1은 높은 RMS, FFT 피크로 가속상태의 구간이다. Cluster 2는 높은 에너지 분포와 불안정한 주파수 특성으로 가속이 빠르게 진행되는 구간이거나 급정거, 부딪힘 등 비정상 구간으로 분류했다. 이러한 군집분포를 통해 얻은 상태 분류 결과를 SLM 학습 모델의 입력에 넣는다.




그림 6 센서 데이터 분석 결과 그림 7 데이터 군집 결과

3.2 YOLOv11 기반 보고서 데이터셋 모델 학습 결과

[그림 8]을 통해 섹션 제목 탐지 모델 전체적인 성능을 나타내는 mAP(Mean Average Precision) 0.5는 59.4%로 측정되었다. big title는 80%, middle title은 63.8%, small title 33.8%으로 객체의 크기가 작을수록 객체 추정이 어려운 경향을 보여준다. [그림 9]를 통해 보고서 내부의 섹션 제목 탐지된 결과를 보여준다.




그림 8 YOLO 모델 성능지표



그림 9 섹션 제목 탐지 모델 성능 결과

3.3 OCR 데이터셋 성능 평가

EasyOCR과 YOLOv11를 활용해서 문서 구조 데이터셋을 구축했다. 총 414,250개의 텍스트가 검출되었으며, [그림 10]을 통해 제목 라벨이 본문 라벨보다 위치가 높은 위치에 있음을 확인했고, [그림 11]에서 섹션 제목은 본문보다 왼쪽에 본포하고 있음을 확인했다. 이를 통해 섹션 제목 별로 구조 목차를 작성하고 목차에 맞는 본문을 생성하기에 알맞은 OCR 결과임을 알 수 있다.




그림 10 섹션 제목 Y 분포도




그림 11 섹션 제목 가로 분포도

3.4 SLM 파인튜닝 모델 성능 평가

[그림 12]에서 볼 수 있듯이 “관련 선행 연구는”과 같이 보고서 주제에 맞는 특징을 일부 반영하는 문장을 생성했으나, 특정 구문을 반복하는 환각(Hallucination)현상을 보였다. 파인튜닝 과정에서 모델이 구조와 내용 흐름을 일관되게 유지하는데 어려움이 있다. 이를 통해 모델 생성능력이 초기단계에 있음을 알 수 있다. 이는 데이터셋의 구조적 한계 및 모델 크기와 관련되어 있다.

보고서 작성: 인공지능 응용: 자율주행 센서 활용

결론

본 연구는 관련 선행 연구는: 인공지능 응용 분야에 있어서는 자율주행 센서 활용을 위한 다양한 방법론이 제시되고 있으며, 이는 자율주행 센서 활용을 위한 다양한 방법론을 제시하고 있다. 이는 자율주행 센서 활용을 위한 다양한 방법론을 제시하고 있다.

이러한 특징은 자율주행 센서 활용을 위한 다양한 방법론을 제시하고 있다. 이는 자율주행 센서 활용을 위한 다양한 방법론을 제시하고 있다. 이는 자율주행 센서 활용을 위한 다양한 방법론을 제시하고 있다.

그림 12 파인튜닝 모델 텍스트 생성결과

3.5 자율주행 로봇에서의 테스트

[그림 13] MW-AHRS v2U IMU sensor를 Jetson orin nano에 연결하여 실제 로봇을 주행시켜 Imu 센서의 값을 뽑아내니 원시 데이터값이 [그림 14]와 같았다.




그림 13 자율주행 로봇에 센서 연결

```
header: angular_velocity_covariance:
stamp: -0.02
sec: 1759134138 -0.0
nanosec: 416983902 -0.0
frame_id: imu_link -0.02
orientation: -0.02
x: -0.7111742362406021 -0.0
y: 0.06089266126132288 -0.0
z: 8.56562131968689e-05 -0.0
w: 0.7003736742730725 -0.02
orientation_covariance: linear_acceleration:
-0.0025 x: -0.93163176
-0.0 y: -9.78593016
-0.0 z: 0.5687857
-0.0 linear_acceleration_covariance:
-0.0025 x: -0.0
-0.0 y: -0.0
-0.0 z: -0.0
-0.0 angular_velocity:
x: -0.16545721308906244 -0.0
y: 0.2712241657589188 -0.0
z: 0.01972222064763592 -0.04
```

그림 14 IMU 센서 값

이를 통해 실시간으로 IMU 데이터를 수집하고 이를 전처리 후, 특징 추출 및 시각화를 거쳐 SLM 모델의 전체 데이터 처리 파이프라인을 구현했다.

3.6 보고서 내용 수정 인터페이스

[그림 15]을 통해 DOCX 문서를 Drop down 방식으로 업로드 할 수 있는 사용자 인터페이스를 구현하였으며, 확인 및 텍스트 형태로 수정할 수 있는 기능을 구현했다. 백엔드는 IO_uring 기반으로 HTTP 통신을 수행하는 멀티스레드 rust 서버로, 실시간 HTTP 요청하는 GPU 추론 환경에서 높은 QPS(Query Per Second)를 지향하였다.



그림 15 사용자 인터페이스

IV. 결론 및 향후 연구 방향

4.1 결론

본 연구에서는 자율주행 로봇의 IMU 센서 데이터를 분석하고 이를 바탕으로 보고서 초안을 자동으로 생성하는 SLM 모델을 구현했다.

시계열 데이터의 노이즈를 제거하고 핵심 특징을 추출하기 위해 IsolationForest, Kalman Filter, FFT를 사용해 군집화하여 CSV로 SLM 모델에 넘겨줄 수 있는 형태로 구성했다.

또한, 보고서 생성을 위한 데이터셋 구축을 위해 YOLOv11 모델로 보고서의 섹션 구조를 파악하고, OCR을 통해 구조화된 JSON 파일로 저장했다. 이를 QLoRA 방식으로 파인튜닝 함으로서 경량화된 보고서 생성 모델을 구축했다.

이를 React와 Rust 기반의 인터페이스로 사용자가 생성된 보고서를 직접 수정하고 편집할 수 있는 환경을 제공했다.

비록 파인튜닝된 SLM의 보고서 생성 성능이 초기상태에 있지만, 향후 모델 성능 향상을 통해 자율주행 로봇의 비정형 데이터를 즉시 분석하여 문서로 구성할 수 있는 전체 파이프라인을 설계하고 구현했다는 점에서 본 연구의 의의를 찾을 수 있다.

4.2 향후 연구 방향

현재 모델 성능의 불확실성은 학습 데이터의 양과 질에 있다. 이는 OCR 과정에서의 오차, 구조화 할때의 오류에 원인이 있다. 또한, 다양한 형태와 보고서를 추가로 확보하고, 큰 한국어 모델을 사용하여 파인튜닝을 진행한다면 모델의 문장 생성 능력을 크게 향상시킬 수 있다.

현재는 로봇의 IMU 센서 데이터만 사용했지만, 카메라 LiDAR, GPS 등 멀티모달 데이터를 활용한다면 실제 상세한 보고서 작성에 도움이 될 것이다.

Acknowledgements

본 연구는 과학기술정보통신부 및 정보통신기획평가원의 SW중심대학사업의 연구결과로 수행되었습니다. (2021-0-01082)

참고문헌

- [1] Dettmers, T., Pagnoni, A., Holtzman, A., & Zettlemoyer, L. (2023). QLoRA: Efficient Finetuning of Quantized LLMs (arXiv:2305.14314). arXiv.
- [2] Youssef, A. (2022). ROSBag Dataset (Turtlebot3). Kaggle.
- [3] Liu, F. T., Ting, K. M., & Zhou, Z. H. (2008). Isolation forest. Proceedings of the 2008 Eighth IEEE International Conference on Data Mining (ICDM) (pp. 413-422). IEEE.
- [4] Welch, G., & Bishop, G. (2006). An introduction to the Kalman filter (TR 95-041). University of North Carolina at Chapel Hill.
- [5] Figo, D., Diniz, P. C., Ferreira, D. R., & Cardoso, J. M. (2010). Preprocessing techniques for context recognition from accelerometer data. Personal and Ubiquitous Computing, 14(7), 645-662.
- [6] 박상현, 이강우. (2019). IMU 센서 기반 시계열 데이터의 특징 추출 및 K-Means 군집화를 통한 보행자 행동 인식. 한국정보과학회 학술발표논문집 (pp. 730-732). 한국정보과학회.
- [7] 한국과학기술정보연구원. (2020). 보고서 목차 자동생성 데이터셋.
- [8] Redmon, J., Divvala, S., Girshick, R., & Farhadi, A. (2016). You only look once: Unified, real-time object detection. Proceedings of the 2016 IEEE Conference on Computer Vision and Pattern Recognition (CVPR) (pp. 779-788). IEEE.
- [9] Baek, Y., Lee, B., Han, D., Yun, S., & Lee, H. (2019). Character region awareness for text detection (CRAFT). Proceedings of the 2019 IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR) (pp. 9516-9525). IEEE.
- [10] EleutherAI. (2023). EleutherAI/polyglot-ko-5.8b. Hugging Face.
- [11] Klabnik, S., & Nichols, C. (2019). The Rust Programming Language. San Francisco: No Starch Press.