


**RICCARDO ANELLI /
POLITECNICO DI MILANO
/ 2022**

PHYSICS-INFORMED NEURAL NETWORKS FOR SHALLOW WATER EQUATIONS



논문 목적과 문제의식

PINN 개념

PINN(Physics-Informed Neural Networks)은 **PDE**를 **loss** 함수에 포함하여 **neural network**를 물리 제약 하에 학습시키는 접근법이다.

- 신경망 + **PDE** 잔차 손실
- 데이터 기반 + 물리 기반 결합

논문의 목적

이 논문의 목적은 **PINN**이 **SWE**를 근사하는 데 유효성을 단계별로 평가하는 것이다.

- **Steady-state** 문제
- **Transient** 문제
- **Parametric many-query** 문제

논문 전체 구조와 읽는 관점

Introduction

논문 목적 및 문제의식 소개

Chapter 1: SWE 배경

Shallow Water Equations의 물리적·수학적 기초

Chapter 2: ML 최소 배경

ANN 구조, 손실 함수, 자동미분 개념

Chapter 3: PINN 알고리즘 및 검증

PINN 구성, 오차 분석, 코드 검증

Chapter 4: 실험 및 결과

Steady, Transient, Parametric, 2D 실험 결과

핵심 정리: 논문은 수학 모델부터 **PINN** 구성,

SWE 벤치마크 실험 순으로 전개

SWE의 물리적 가정

핵심 가정 목록

- 얇은 수심 가정 (**shallow water**)
- 정수압 가정 (**hydrostatic pressure**)
- 수직 속도 및 가속도 무시
- **2D depth-averaged flow**
- 비압축성 유체 (**incompressible**)
- 연속체 가정 (**continuum**)

단면 개념도 설명

자유수면(**free surface**)과 수심(**h**), 지형(**bottom topography**)의 관계를 단순화한 **2D** 단면 구조.

수직 방향 속도와 가속도는 무시되며, 압력은 정수압 분포를 따른다.

SWE의 수학적 구조

보존형 벡터 방정식

$$\frac{\partial \mathbf{U}}{\partial t} + \frac{\partial \mathbf{E}}{\partial x} + \frac{\partial \mathbf{G}}{\partial y} = \mathbf{S}$$

- **U**: 상태 벡터 (h, q_x, q_y)
- **E**: x 방향 플럭스 벡터
- **G**: y 방향 플럭스 벡터
- **S**: 소스항 벡터

벡터 구성 요소

$$\mathbf{U} = \begin{bmatrix} h \\ hu \\ hv \end{bmatrix}, \quad \mathbf{E} = \begin{bmatrix} hu \\ hu^2 + \frac{1}{2}gh^2 \\ huv \end{bmatrix}, \quad \mathbf{G} = \begin{bmatrix} hv \\ huv \\ hv^2 + \frac{1}{2}gh^2 \end{bmatrix}$$

$$\mathbf{S} = \begin{bmatrix} R - I \\ gh(S_{0x} - S_{fx}) + \mu S_{dx} \\ gh(S_{0y} - S_{fy}) + \mu S_{dy} \end{bmatrix}$$

SOURCE TERM, 마찰 법칙, 경계 조건

Source Term 구성

- 포함: **Topography** (지형 경사), **Friction** (바닥 마찰)
- 제외: **Rain, Infiltration, Viscosity**

마찰 법칙 비교

- **Manning-Strickler:**

$$S_{f_x} = n^2 \frac{u|\mathbf{u}|}{h^{4/3}} = n^2 \frac{q_x|\mathbf{q}|}{h^{10/3}}$$

$$S_{f_y} = n^2 \frac{v|\mathbf{u}|}{h^{4/3}} = n^2 \frac{q_y|\mathbf{q}|}{h^{10/3}}$$

- **Darcy-Weisbach:**

$$S_{f_x} = C_f \frac{u|\mathbf{u}|}{h} = C_f \frac{q_x|\mathbf{q}|}{h^3}$$

$$S_{f_y} = C_f \frac{v|\mathbf{u}|}{h} = C_f \frac{q_y|\mathbf{q}|}{h^3}$$

- **Froude 수:**

$$\text{Fr} = \frac{|\mathbf{u}|}{\sqrt{gh}}$$

Scaling for the SWE

- **SWE** 큰 문제는 공간/시간 스케일과 작은 해의 크기를 동시에 가질 수 있음
- **NN**은 보통 **O(1)**규모의 입력/출력에서 더 안정적으로 학습
- 따라서 물리 문제를 **NN** 친화적인 크기로 옮기는 **scaling**이 필요함

$$\bullet x = \mathbf{L} \tilde{x}$$

$$\bullet y = \mathbf{L} \tilde{y}$$

$$\bullet z = \mathbf{H} \tilde{z}$$

$$\bullet t = \mathbf{T} \tilde{t}$$

$$\bullet h = \mathbf{H} \tilde{h}$$

$$\bullet u = \mathbf{U} \tilde{u}$$

$$\bullet v = \mathbf{U} \tilde{v}$$

scaling은 단순한 형식 변화가 아니라 **PINN** 학습 안정성을 위한 전처리

논문은 특정 관계를 두면 **scaled form**과 **original form**의 구조가 같아질 수 있다고 설명

Scaling은 **SWE**를 **NN**이 다루기 쉬운 크기로 옮겨 **PINN** 학습 안정성을 높이는 핵심 단계

ANN의 최소 배경

- **ANN** 기본 구조: 입력층 $\rightarrow$ 은닉층(활성화 함수) $\rightarrow$ 출력층

logit: 활성화 전 값

weight: 연결 강도

bias: activation 이동

activation: 비선형성 부여, 뉴런의 최종 출력

PINN에서는 입력이 $(\mathbf{x}, t)$, $(\mathbf{x}, \mathbf{y}, t)$ 또는 **parameter**까지 포함한 형태

출력은 **h**, **u**, **v** 또는 관련 **state variable**

ANN은 데이터를 분류하는 모델이 아니라, **PDE** 해를 직접 근사하는 **surrogate network**

input layer: $\mathcal{N}^0(\mathbf{x}) = \mathbf{x} \in \mathbb{R}^{d_{in}}$

hidden layers: $\mathcal{N}^\ell(\mathbf{x}) = \sigma(\mathbf{W}^\ell \mathcal{N}^{\ell-1}(\mathbf{x}) + \mathbf{b}^\ell) \in \mathbb{R}^{N_\ell}, \text{ for } 1 \leq \ell \leq L-1$

output layer: $\mathcal{N}^L(\mathbf{x}) = \mathbf{W}^L \mathcal{N}^{L-1}(\mathbf{x}) + \mathbf{b}^L \in \mathbb{R}^{d_{out}}$

$$\begin{aligned} z_1^{(1)} &= w_{1,1}^{(1)} a_1^{(0)} + w_{1,2}^{(1)} a_2^{(0)} + \cdots + w_{1,n}^{(1)} a_n^{(0)} + b_1^{(1)} \\ &= \sum_{k=1}^n w_{1,k}^{(1)} a_k^{(0)} + b_1^{(1)} \end{aligned} \quad (2.1)$$

where:

- $z_1^{(1)}$ is the *logit*, a number still to be handled in order to get a valid neuron value, it's associated with the first hidden layer's neuron;
- $a_k^{(0)}$ is the value stored in the k -th input layer's neuron, it's called *activation*;
- n is the number of neurons belonging to the input layer;
- $w_{1,k}^{(1)}$ is the weight associated to the connection between $a_k^{(0)}$ and the first hidden layer's neuron;
- $b_1^{(1)}$ is the bias associated with the first hidden layer's neuron.

LOSS, BACKPROPAGATION, AUTOMATIC DIFFERENTIATION

학습 흐름

1. **forward pass**: 입력이 네트워크를 통과해 출력 생성
2. **loss computation**: 예측값과 목표값, 또는 물리 잔차를 비교해 손실 계산
3. **backpropagation**: chain rule을 이용해 각 parameter의 gradient 계산
4. **parameter update**: gradient descent/ Adam으로 parameter 갱신

- PINN에서는 network output의 편미분이 필요함
- AD가 PDE residual 계산에 직접 사용됨
- reverse-mode AD는 backpropagation과 연결됨

방법	특징	한계
Numerical differentiation	구현 단순	근사 오차 존재
Symbolic differentiation	정확한 표현 가능	expression swell
Automatic differentiation	기계 정밀도 수준, 효율적	PINN에 가장 적합

PINN은 **AD**를 이용해 네트워크 출력의 편미분을 계산하고, 이를 **PDE RESIDUAL** 손실에 직접 반영한다.

PINN 알고리즘 및 오차 분석




Figure 3.1: PINN algorithm. 1D heat equation. (from Ref. [25]).

PINN 학습 흐름도

데이터 준비 → 신경망 초기화 → 손실 함수 계산(PDE residual + BC-IC)

→ 경사 하강법(Adam, L-BFGS) → 수렴 판단

Surrogate network 정의

unknown solution의 대리모델로 둬

Training points 설정

domain 내부와 boundary에 점 집합 배치

Residual 계산

PDE residual + BC/IC residual 계산

Loss minimization

loss를 최소화하도록 업데이트

오차 분석 및 Hyperparameter

- **Error bound:** 총 오차 = 근사 오차 + 최적화 오차 + 일반화 오차

$$\mathcal{E} \stackrel{\text{def}}{=} \|\tilde{u}_{\mathcal{T}} - u\| \leq \mathcal{E}_{\text{app}} + \mathcal{E}_{\text{gen}} + \mathcal{E}_{\text{opt}} \quad (3.11)$$

- 잔차(residual) 해석: PDE 잔차가 작아도 실제 해와 차이 존재 가능

- **Hyperparameter** 영향: 네트워크 깊이, 너비, 학습률, **collocation point** 수

CODE VALIDATION

1. Poisson equation

- **elliptic problem**
- **parametric setting** 포함
- 해석해가 존재하므로 **PINN** 해와 직접 비교 가능

$$\begin{cases} -\frac{\partial^2 u}{\partial x^2} = f(x, \kappa) & \text{in } \Omega \\ u(0, \kappa) = u(1, \kappa) = 0 \end{cases} \quad (3.12)$$

2. Heat equation

- **parabolic problem**
- 시간의존 문제에서 **PINN** 동작 검증
- **exact solution**과 비교 가능

$$\begin{cases} \frac{\partial u}{\partial t} - \frac{\partial^2 u}{\partial x^2} = f(x, \kappa, t) & \text{in } \Omega \times (0, T) \\ u = 0 & \text{in } \Omega : t = 0 \\ u(0, \kappa, t) = u(1, \kappa, t) = 0 \end{cases} \quad (3.16)$$

3. Burgers' equation

- **nonlinear hyperbolic problem**
- **shock wave**가 등장하는 대표적 예시
- **SWE**와 같은 **hyperbolic** 계열 문제 전 검증 역할

$$\begin{cases} \frac{\partial u}{\partial t} + u \frac{\partial u}{\partial x} = 0 & \text{in } \Omega \times (0, T) \\ u = u_0 & \text{in } \Omega : t = 0 \\ u = 1 & \text{on } \partial\Omega_{in} \times (0, T) \end{cases} \quad (3.20)$$

실험 전체 구조

Results chapter의 전개 논리

- **Steady-state problems**
hydrostatic equilibrium과 **subcritical flow** 검증
- **Transient 1D dam-break problems**
wet / dry / friction 포함 문제
- **Parametric problems**
friction coefficient C 또는 **gravity g**를 입력 변수로 포함
- **2D extension**
circular dam-break problem

비교 기준은 문제에 따라 다름
exact / analytic solution
FullSWOF_1D
LSS scheme

즉, 모든 결과가 같은 기준으로 검증된 것은 아님

Section별 실험 구조 표

Section	Problem	Type	핵심 검증 포인트
4.2	Lake at rest with an immersed bump	Steady-state	hydrostatic equilibrium
4.3	Lake at rest with an emerged bump	Steady-state	wet/dry transition
4.4	Subcritical flow	Steady-state	BC 포함 steady solution
4.5	Dam break on a wet domain	Transient	shock + rarefaction
4.6	Dam break on a wet domain with	Transient / Parametric	friction + parameter
4.7	Dam break on a dry domain	Transient	dry front
4.8	Dam break on a dry domain with	Transient	dry front + friction
4.9	Dam break on a dry domain with	Parametric	parameterized friction
4.1	Circular dam break	2D transient	symmetry / 2D SWE
4.11	Circular dam break, parametric	2D parametric	gravity parameter

Steady-state Problems

문제 구성

4.2 Lake at rest with an immersed bump




- 바닥 지형이 물속에 잠겨 있음
- 정지 수면(hydrostatic equilibrium) 유지가 핵심

4.3 Lake at rest with an emerged bump


- 바닥 지형 일부가 수면 위로 드러남
- wet/dry transition이 포함됨

4.4 Subcritical flow

- 일정한 유입/유출 조건이 있는 정상 유동
- boundary condition이 포함된
- steady-state problem



(a)



(b)

문제 검증 요약

문제	검증 포인트
Immersed bump	정지 수면 보존, hydrostatic
Emerged bump	wet/dry transition 처리
Subcritical flow	BC가 포함된 steady solution 재현


steady-state 문제는 PINN이 hydrostatic equilibrium, wet/dry transition, BC가 포함된 정상 해를 재현할 수 있는지 보여준다.

Dam Break on Wet and Dry Domains

문제 구성


4.5 Dam break on a wet domain

- 하류에도 물이 존재하는 초기조건
- 대표적인 **Riemann problem**
- **shock wave**와 **rarefaction wave**가 함께 나타남



4.7 Dam break on a dry domain

- 하류 수심이 **0**인 초기조건
- **moving dry front**가 형성됨
- **wet case**보다 더 어려운 **transient benchmark**



문제 검증 요약

문제	검증 포인트
Wet domain dam break	shock / rarefaction 구조 재현
Dry domain dam break	moving wet/dry front 재현


- **wet case**는 **Stoker solution**과 비교
- **dry case**는 **Ritter solution**과 비교
- 두 경우 모두 **analytic solution**이 존재해서 **PINN** 해와 직접 비교 가능

Friction and Parametric 1D cases

문제 구성


4.6 Dam break on a wet domain with friction, parametric

- wet domain dam-break에 friction term 포함
- exact solution이 없어서 FullSWOF_1D와 비교
- parameterized friction case까지 같이 다룸




4.8 Dam break on a dry domain with friction

- dry front와 friction이 동시에 존재
- wet/dry transition + 마찰항이 겹쳐 더 어려운 문제



4.9 Dam break on a dry domain with friction, parametric

- dry + friction 문제를 parameterized PINN으로 확장
- friction coefficient C를 입력 변수로 포함



문제 검증 요약

문제	검증 포인트
Wet + friction	friction이 들어간 transient structure
Dry + friction	dry front + friction 동시 처리
Parametric friction	하나의 network가 여러 C 값을 다룰 수 있

- friction이 포함된 dam-break 문제는 analytic solution이 없는 경우가 있어 reference solver와 비교한다
- dry domain에서는 wet/dry front와 마찰항이 동시에 존재해 더 어려운 transient benchmark가 된다

2D Circular Dam Break

문제 구성

2D circular dam-break

- 초기에는 원형 영역 내부와 외부의 수위가 다름
- 시간이 흐르면서 방사형으로 **wave**가 전파됨
- 미지수는


$$h(x,y,t)$$

$$u(x,y,t)$$

$$v(x,y,t)$$

문제 검증 요약

항목	의미
2D SWE 적용	1D에서 2D로의 차원 확장
Symmetry preservation	원형 초기조건의 대칭 구조 유지
Reference comparison	LSS scheme과 비교
Variable expansion	h, u, v 세 변수 동시 예측



circular dam-break는 2D SWE의 대표적 **benchmark**
원형 초기조건이기 때문에 결과도 대체로 대칭 구조를 유지해야 함
논문은 PINN 해와 LSS scheme 결과를 비교해 전반적 구조 유지 여부를 확인한다

Parametric 2D Case


Gravity as Parameter

문제 구성

- 2D circular dam-break, parametric
- 기존 2D 문제의 입력 (x, y, t) 에 gravity g 를 추가
- 따라서 네트워크 입력은
- (x, y, t, g)
- 출력은 그대로
- (h, u, v)

문제 검증 요약

항목	의미
Parametric 2D extension	2D SWE에 parameter
Gravity as input	물리 파라미터를 network input에 포
Symmetry preservation	대부분의 parameter space에서 대칭 구조
Generalization in parameter space	여러 g 값에 대해 하나의 network로 근사



- 논문은 예시로 $g = 1, 4, 8, 12, 16, 20$ 결과를 제시한다
- parameter가 달라도 circular structure와 symmetry가 전반적으로 유지되는지를 본다
- 이는 2D many-query setting의 가능성을 보여주는 사례다

PINN이 SHOCK를 근사하는 방식

PINN이 shock를 근사하는 방식

- PINN은 해를 연속적이고 미분가능한 **neural network** 함수로 표현
- 따라서 **sharp discontinuity**를 직접 표현하기보다
- 학습 과정에서 부드러운(**smooth**) 형태로 근사하는 경향이 있음
- **PDE** 잔차 최소화 기반 학습
- 자동미분(**AD**)으로 공간 도함수 계산

PINN은 **neural network**로 해를 연속적으로 근사하기 때문에, **shock**가 포함된 문제에서도 **sharp discontinuity**를 직접 표현하기보다는 **smooth approximation**을 형성하는 경향이 있다

Reference solution과의 차이

항목	PINN 결과의 경향
Shock 위치	비교적 잘 재현
전체 wave structure	전반적으로 유지
급격한 gradient	reference보다 더 smooth
Dry front / friction 포함 case	구조는 유지되지만 sharpness는 약화 가능

- **Shock** 형태: **smoothing** 현상 발생
- 해의 연속성: 미분가능한 해 생성
- 물리적 일관성: 보존법칙 약한 만족

그럼에도 불구하고 **shock** 위치와 전체 **wave pattern**은 비교적 잘 재현된다
따라서 이 논문 결과는 PINN이 **hyperbolic SWE**에 적용 가능성을 보여주면서도,
sharp gradient 처리의 한계를 동시에 드러낸다고 해석할 수 있다

논문 주요 한계 및 고려사항

높은 **Training** 비용: **PINN** 학습은 **PDE** 잔차 계산과 자동미분으로 인해 상당한 계산 자원과 시간이 소요된다.

특히 복잡한 문제나 고해상도 학습점 사용 시 비용이 급격히 증가한다.

Scaling 및 **Hyperparameter Tuning** 어려움: 네트워크 구조, 학습률, 손실 가중치 등 **hyperparameter** 선택이 **trial-and-error**에 크게 의존하며, 문제별 최적 설정을 찾기 위한 체계적 방법론이 부족하다.

전통 수치해석법 대체의 한계: **FEM, FVM, FDM** 등 기존 수치해석법은 수십 년간 검증된 안정성과 정확도를 갖추고 있어, **PINN**이 이를 직접 대체하기보다는 보완적 도구로 활용되는 것이 현실적이다.

SWE에 PINN 적용 가능성 실험적 확인

Parametric many-query 접근 유망성

Shock 및 복잡한 경계조건 처리에서 한계 존재

고비용과 튜닝 어려움은 향후 연구 과제

핵심 정리: 본 논문은 **SWE** 문제에 대한 **PINN**의 잠재력과 한계를 학술적으로 균형 있게 제시한다